

סיווג אודיו של שיחות טלפון – דו"ח ניסויים

1. מטרה

אימון מודל למידת מכונה שמסווג קטעי אודיו של שיחות טלפון לאחת מארבע קטגוריות:

קטגוריה	תיאור
human	נציג אנושי חי
ivr	תפריט אינטראקטיבי ("הקש 1 לעברית")
music	מוזיקת המתנה
recording	הקלטה / תא קולי / הודעה מוקלטת

המודל נדרש לתמוך גם בקטעים קצרים מ-5 שניות (עד 0.3 שניות), כי נציגים אנושיים עונים לעיתים במילה בודדת ("היי", "שלום").

2. מאגר הנתונים

הניסויים נערכו על שתי גרסאות של המאגר:

מאגר א' (ראשוני)

229 חתיכות לאחר חיתוך ל-5 שניות:

קטגוריה	חתיכות
human	103
ivr	54
music	60
recording	12

פיצול: אימון 158 / אימות 35 / בדיקה 36.

מאגר ב' (מורחב)

274 חתיכות — לאחר הוספת הקלטות recording :

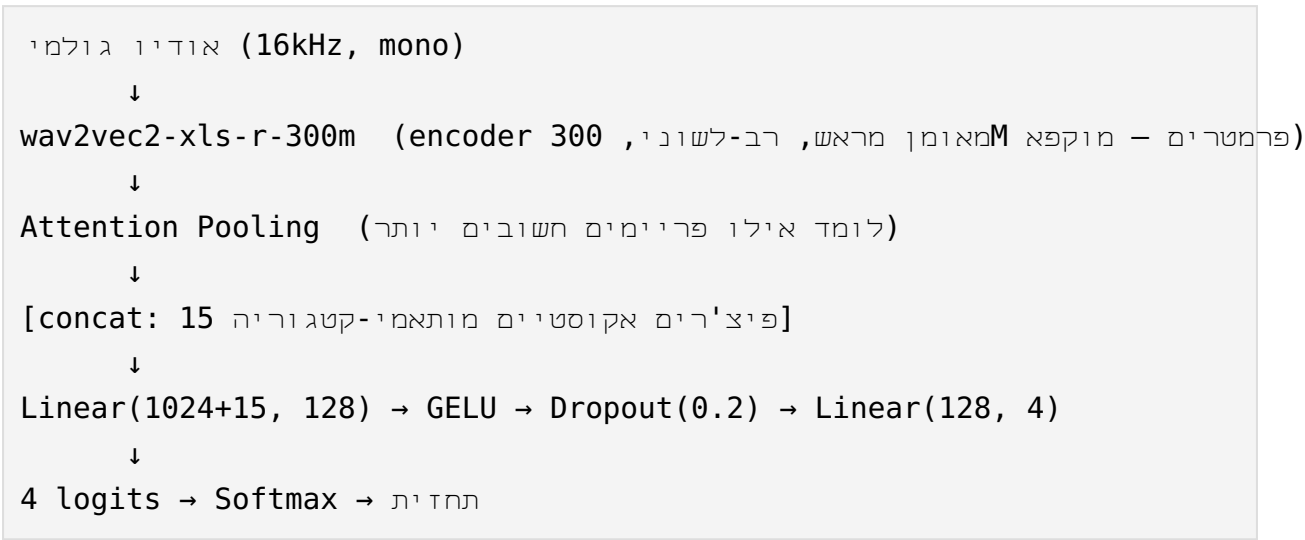
קטגוריה	חתיכות
human	103
ivr	54
music	60

קטגוריה	חתיכות
recording	57

פיצול: אימון 189 / אימות 42 / בדיקה 43.

הערה מתודולוגית: הפיצול ל-train/val/test נעשה **לפי הקלטת מקור** (כל החתיכות מאותו קובץ הולכות לאותו פיצול) ועם stratification על הקטגוריה — כדי למנוע דליפת מידע (data leakage) שהייתה מנפחת את ציון הבדיקה.

3. ארכיטקטורת המודל



- ה-encoder מוקפא; מתאמן רק ראש הסיווג (~133K פרמטרים מתוך 315M).
- Class weights מפצים על חוסר איזון בין הקטגוריות.
- Augmentations (רעש, gain, pitch-shift, time-stretch) על קבוצת האימון בלבד.
- Early stopping מבוסס macro F1 על קבוצת האימות.

4. הפיצ'רים האקוסטיים (Feature Engineering)

15 פיצ'רים, כל אחד מכוון להבחנה של קטגוריה ומבוסס על אלגוריתם מקובל (librosa). כולם מנורמלים לסקלה פיזית קבועה ונחתכים לטווח [5, -5].

קטגוריה יעד	פיצ'ר	אלגוריתם	הצדקה
music	tempo_bpm	beat tracking	מוזיקה בעלת קצב יציב
music	beat_strength	onset envelope	onset חזקים וסדירים
music	harmonic_ratio	HPSS	ספקטרום הרמוני נקי
music	chroma_std	chroma STFT	מגוון צלילים רחב
ivr	dtmf_energy	יחס אנרגיה בתדרי DTMF	צלילי חיוג

קטגוריה יעד	פיצ'ר	אלגוריתם	הצדקה
ivr	pitch_stability	std של pitch	קול סינתטי יציב
ivr	silence_ratio	יחס פריימים שקטים	פאוזות מובנות
human	pitch_range	אחוזון 5–95 של pitch	טון דינמי
human	breath_events	זיהוי נשימות	נשימות אנושיות
human	voiced_ratio	יחס פריימים קוליים	דיבור חי
recording	bandwidth_hz	rolloff 99%	פסקול דחוס (codec)
recording	rolloff_hz	rolloff 85%	רולוף נמוך
recording	noise_floor_db	אחוזון 10 של אנרגיה	רצפת רעש קבועה
כללי	zcr_mean	zero-crossing rate	הבחנה רעש/דיבור/מוזיקה
כללי	spectral_centroid_hz	spectral centroid	בהירות ספקטרלית

5. הניסויים

הגדרות קבועות בכל הריצות: מודל בסיס wav2vec2-xl-s-r-300m , batch size 8.

טבלת כל הריצות

#	מאגר	פיצ'רים	LR	unfreeze	patience	epochs	Test Acc	Macro F1
1	א' (rec=12)	5 נשימה (לא מנורמל)	1e-4	2	5	14	0.3889	0.2303
2	א' (rec=12)	5 נשימה (מנורמל)	1e-4	2	5	7	0.2500	0.1000
3	א' (rec=12)	ללא	5e-4	0	15	33	0.9167	0.7094
4	א' (rec=12)	5 נשימה (מנורמל)	5e-4	0	15	40	0.7500	0.5577
5	ב' (rec=57)	15 מותאמי-קטגוריה	1e-4	2	5	11	0.4186	0.3440
6	ב' (rec=57)	15 מותאמי-קטגוריה	5e-4	0	15	37	0.7674	0.7518
7	ב' (rec=57)	ללא	5e-4	0	15	21	0.5581	0.5426

F1 לכל קטגוריה

#	פיצ'רים	human	ivr	music	recording
1	5 נשימה (לא מנורמל)	0.4348	0.0000	0.4865	0.0000
2	5 נשימה (מנורמל)	0.0000	0.0000	0.4000	0.0000
3	ללא	0.9375	0.9000	1.0000	0.0000
4	5 נשימה (מנורמל)	0.7692	0.4615	1.0000	0.0000
5	15 (הגדרות גרועות)	0.4615	0.0000	0.5143	0.4000
6	15 (הגדרות נכונות)	0.7692	0.5714	1.0000	0.6667
7	ללא	0.0000	0.5294	0.9412	0.7000

6. ניתוח

6.1 ההגדרות חשובות יותר מהמודל

ריצות 1-2 (LR=1e-4, unfreeze=2, patience=5) קרסו: ה- `train_loss` כמעט לא ירד (1.39 → 1.29), כלומר המודל לא הצליח ללמוד אפילו את קבוצת האימון. עצם המעבר ל-LR=5e-4, הקפאת ה-encoder המלאה (unfreeze=0) ו-patience=15 (ריצה 3) הקפיץ את ה-Macro F1 מ-0.10 ל-0.71 — **על אותו מודל ואותו דאטה**. מסקנה: על מאגר קטן, fine-tuning של שכבות encoder מזיק (יותר מדי פרמטרים), ו-LR נמוך מדי מונע מראש הסיווג להתכנס.

6.2 ערך ה-Feature Engineering תלוי בדאטה

ממצא מרכזי ולא-טריוויאלי:

מאגר	בלי פיצ'רים	עם פיצ'רים
א' (rec=12)	0.7094 (ריצה 3)	0.5577 (ריצה 4, 5 נשימה)
ב' (rec=57)	0.5426 (ריצה 7)	0.7518 (ריצה 6, 15 מותאמים)

- **על מאגר א' הקטן והלא-מאוזן, הפיצ'רים הזיקו** — `wav2vec2` לבד הספיק, והפיצ'רים (5) פיצ'רי נשימה, כולם על "דיבור אנושי") רק בלבלו את ההבחנה בין `ivr` ל-`human`.
- **על מאגר ב' המורחב, הפיצ'רים הפכו לקריטיים** — בלעדיהם המודל **קרס לחלוטין על `human`** (F1=0.00: כל 15 ההקלטות האנושיות סווגו כ-`ivr` או `recording`). הפיצ'רים העלו את `human` מ-0.00 ל-0.77.

ההסבר: ככל שהמאגר גדל והתאזן (recording 12→57), המשימה נעשתה קשה יותר — ארבע קטגוריות שכולן (חוץ ממוזיקה) מכילות דיבור. במצב הזה, פיצ'רים גלובליים מותאמי-קטגוריה (`tempo`, `DTMF`, רוחב-פס, דינמיקת `pitch`) מספקים אות משלים ש-`wav2vec2` — המאומן על דיבור — לא תופס לבדו.

6.3 השפעת הוספת הדאטה ל-recording

בכל הריצות על מאגר א' (recording=12), קטגוריית recording קיבלה 8 — $F1=0.00$ דוגמאות אימון פשוט לא הספיקו. לאחר ההרחבה ל-57, recording הגיע ל-0.67-0.70. $F1=0.67$. זו הדגמה ישירה לחשיבות כמות הדוגמאות לכל מחלקה.

7. מטריצות בלבול (ריצות מרכזיות, מאגר ב')

ריצה 6 — 15 פיצ'רים + הגדרות נכונות (המודל הנבחר):

אמת	חידוי			
	human	ivr	music	recording
human	15	0	0	0
ivr	5	4	0	1
music	0	0	9	0
recording	4	0	0	5

ריצה 7 — בלי פיצ'רים:

אמת	חידוי			
	human	ivr	music	recording
human	0	12	0	3
ivr	0	9	0	1
music	0	1	8	0
recording	0	2	0	7

human קריסה מוחלטת על ←

8. מסקנות

1. המודל הנבחר: ריצה 6 — wav2vec2-xls-r-300m מוקפא + 15 attention pooling. פיצ'רים אקוסטיים, על המאגר המורחב. **Macro F1 = 0.75, 76.7%** דיוק.
2. **Feature engineering תורם** על המאגר הנוכחי: +0.21 ב-Macro F1 לעומת המודל בלי פיצ'רים, והצלת קטגוריית human מקריסה.
3. **כיוון hyperparameters קריטי:** אותם פיצ'רים עם הגדרות שגויות נתנו רק 0.34.
4. **כמות הדאטה לכל מחלקה מכריעה:** recording עבר מ- $F1=0$ (8 דוגמאות) ל- $F1=0.67$ (39 דוגמאות).

9. מגבלות וכיווני המשך

- **ivr עדיין החלש** ($F1=0.57$, recall 0.40) — מתבלבל עם human. כיוונים: עוד דאטה ל-ivr, או חיזוק הפיצ'רים המכוונים אליו (pitch_stability, dtmf_energy).
- **מאגר קטן יחסית** (274 חתיכות) — ביצועים עשויים להשתפר עם עוד דאטה ובדיקה על מאגר חיצוני.
- **חוסר איזון שיורי** — recording עדיין הקטגוריה הקטנה ביותר.